Exploration de graphes sociaux

Analyse des centralités, communautés, interprétation métier et prédiction de liens
Application au dataset *Facebook Social Circles*

Tambat Tresor Megane Nkwé Ebongué Brenda Muriel Siaba Nguimgue Emmanuel Bernard Arthur

INF1853 – Introduction à l'intelligence artificielle

Plan

1. Introduction
2. Jeu de données et méthodologie
3. Résultats structurels
4. Analyse locale
5. Interprétation métier
6. Prédiction de liens
7. Discussion et conclusion

Contexte

Les réseaux sociaux peuvent être modélisés sous forme de graphes :

- les **nœuds** représentent les utilisateurs ;
- les **arêtes** représentent les relations entre utilisateurs.

Dans ce projet, nous analysons le dataset *Facebook Social Circles* afin de :

- repérer les nœuds les plus importants ;
- détecter des communautés ;
- comparer les communautés détectées aux *circles* fournis ;
- prédire des liens entre utilisateurs.

Objectifs du projet

L'objectif principal est d'explorer un réseau social Facebook en répondant aux questions suivantes :

1. Quels sont les nœuds les plus centraux dans le réseau ?
2. Quelles communautés peut-on détecter automatiquement ?
3. Dans quelle mesure ces communautés recouvrent-elles les *circles* du dataset ?
4. Comment traduire ces résultats dans une logique métier ?
5. Peut-on prédire automatiquement les liens entre utilisateurs ?

Dataset utilisé

Dataset : **Facebook Social Circles** (SNAP)

Fichiers exploités :

- `facebook_combined.txt.gz` : graphe global ;
- `facebook.tar.gz` : ego-networks détaillés ;
- `nodeId.edges` : arêtes d'un ego-network ;
- `nodeId.circles` : groupes sociaux de l'ego ;
- `nodeId.feat`, `nodeId.egofeat`, `nodeId.featnames` : caractéristiques anonymisées.

Prétraitement

Les principales étapes de préparation des données sont :

- lecture du fichier `facebook_combined.txt.gz` ;
- construction du graphe global non orienté ;
- extraction de l'archive `facebook.tar.gz` ;
- sélection de deux ego-networks : **0** et **107** ;
- ajout explicite du nœud ego dans chaque sous-graphe ;
- lecture des *circles* et des caractéristiques anonymisées.

Le graphe global contient une seule composante connexe.

Méthodes utilisées

Analyse de graphe

- statistiques structurelles ;
- centralité de degré ;
- centralité de proximité ;
- centralité d'intermédiarité ;
- PageRank ;
- détection de communautés avec **Louvain**.

Extensions

- couche d'interprétation métier ;
- prédiction de liens avec modèles classiques et GNN.

Résultats globaux du graphe

Mesure	Valeur
Nombre de nœuds	4039
Nombre d'arêtes	88234
Densité	0.010820
Degré moyen	43.6910
Nombre de composantes connexes	1
Clustering moyen	0.6055
Communautés Louvain	17
Modularité	0.8349

Lecture : réseau peu dense, entièrement connecté et fortement structuré.

Distribution des degrés

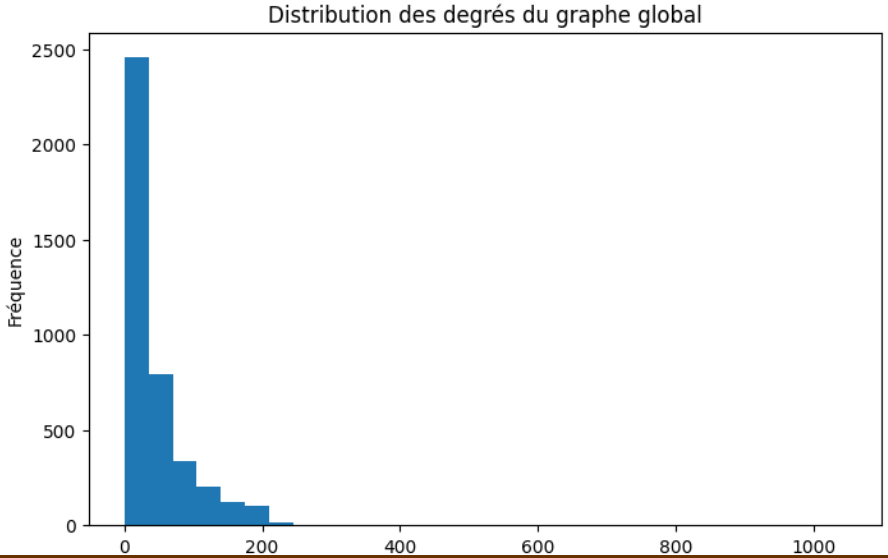

Nœuds les plus centraux

Nœud	Degré	Proximité	Intermédiarité	PageRank
107	0.258791	0.459699	0.480518	0.006936
1684	0.196137	0.393606	0.337797	0.006367
1912	0.186974	0.350947	0.229295	0.003877
3437	0.135463	0.314413	0.236115	0.007615
0	0.085934	0.353343	0.146306	0.006290

Observation :

- le nœud 107 domine plusieurs mesures ;
- 3437 obtient le meilleur score PageRank.

Ego-network 0

Résultats pour l'ego-network du nœud **0** :

- **334 nœuds**
- **2852 arêtes**
- **24 circles**
- **9 communautés Louvain**
- **modularité = 0.4286**

Plus grands circles :

- `circle15` : 133 membres
- `circle16` : 32 membres
- `circle11` : 30 membres

Ego-network 107

Résultats pour l'ego-network du nœud **107** :

- **1035 nœuds**
- **27783 arêtes**
- **9 circles**
- **6 communautés Louvain**
- **modularité = 0.5273**

Plus grand circle :

- `circle6` : 308 membres

Visualisation des ego-networks

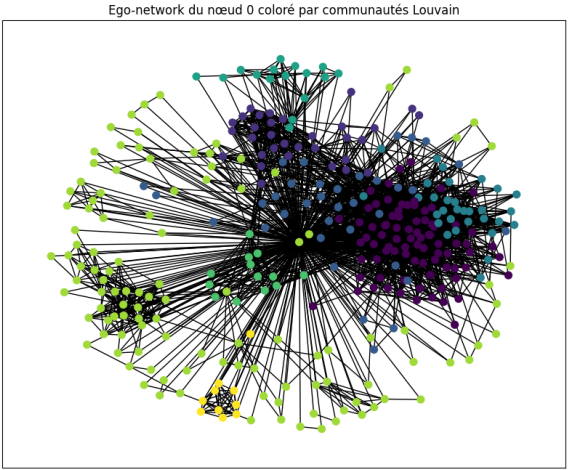

Ego-network 0

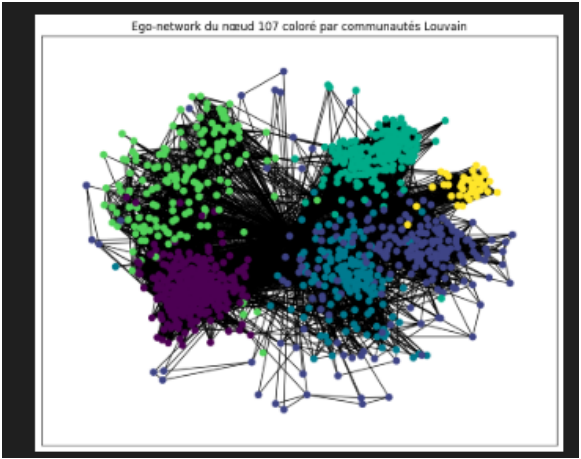

Ego-network 107

Comparaison ego 0 vs ego 107

Ego	Nœuds	Arêtes	Circles	Modularité
0	334	2852	24	0.4286
107	1035	27783	9	0.5273

Interprétation :

- l'ego 107 est plus vaste et plus dense ;
- sa modularité est plus élevée ;
- l'ego 0 possède davantage de circles annotés.

Comparaison Louvain vs circles

Circle	Taille	Communauté	Chevauchement	Jaccard
circle15	133	0	65	0.373563
circle6	20	5	15	0.340909
circle16	32	1	15	0.312500
circle19	13	5	12	0.300000
circle11	30	0	20	0.172414

Lecture : cohérence partielle entre groupes détectés automatiquement et groupes annotés.

Ajout d'une couche métier

Pour rendre le projet plus concret, nous avons ajouté une couche d'interprétation métier :

- calcul d'un score global d'importance ;
- classification des nœuds :
  - acteur influent ;
  - acteur accessible ;
  - acteur intermédiaire ;
  - acteur périphérique.
- classification des communautés :
  - groupe stratégique majeur ;
  - grand groupe structuré ;
  - groupe cohésif ;
  - groupe intermédiaire.

Acteurs clés identifiés

Nœud	Score global	Rôle
107	0.982090	Acteur influent
1684	0.758283	Acteur influent
428	0.246319	Acteur accessible
563	0.236762	Acteur accessible
58	0.216115	Acteur accessible

Utilité entreprise :

- repérer des relais d'information ;
- identifier des clients ambassadeurs ;
- cibler des acteurs stratégiques.

Problématique prédictive

Question étudiée :

Peut-on prédire automatiquement si deux utilisateurs devraient être connectés à partir de la structure du graphe ?

Intérêt :

- recommandation de contacts ;
- détection d'opportunités relationnelles ;
- aide à la collaboration ;
- extension du projet vers une tâche d'apprentissage supervisé.

Modèles testés

Modèles classiques

- Logistic Regression
- Random Forest
- Gradient Boosting

Modèle neuronal sur graphes

- GraphSAGE avancé
- features de nœuds
- features de paire
- décodeur MLP
- hard negative sampling

Résultats des modèles classiques

Modèle	F1-score	AUC
Logistic Regression	0.9704	0.9955
Random Forest	0.9787	0.9969
Gradient Boosting	0.9734	0.9967

Observation :

- les trois modèles sont très performants ;
- le Random Forest est le meilleur modèle classique.

Résultats du GNN avancé

GraphSAGE avancé sur l'ensemble de test :

- **accuracy = 0.9747**
- **precision = 0.9824**
- **recall = 0.9667**
- **F1-score = 0.9745**
- **AUC = 0.9960**

Conclusion : le modèle GNN devient très compétitif après enrichissement.

Historique d'entraînement du GNN

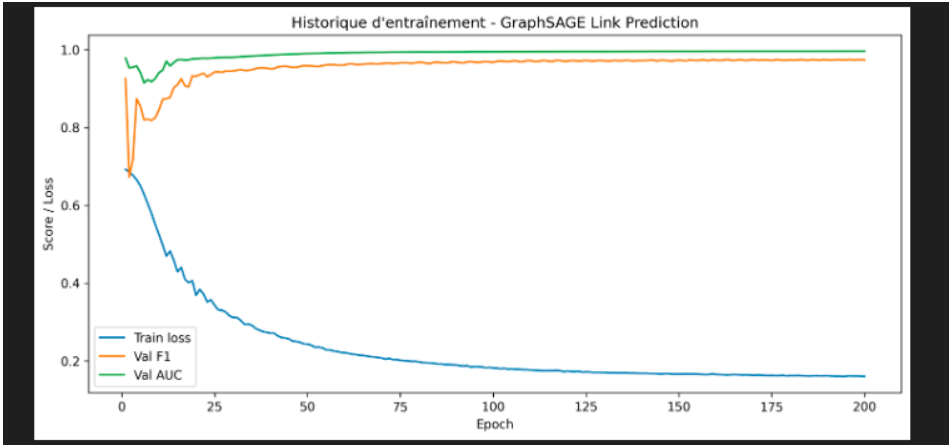

La loss d'entraînement baisse régulièrement, tandis que les performances de validation se stabilisent à un niveau élevé.

Comparaison finale des modèles

Modèle	F1-score	AUC
Logistic Regression	0.9704	0.9955
Random Forest	0.9787	0.9969
Gradient Boosting	0.9734	0.9967
GraphSAGE avancé	0.9745	0.9960

Lecture :

- les modèles classiques restent légèrement supérieurs ;
- le GNN avancé est désormais au même ordre de grandeur.

Discussion

Les principaux constats sont les suivants :

- le réseau global possède une organisation communautaire forte ;
- quelques nœuds, en particulier **107** et **3437**, occupent des positions dominantes ;
- les communautés Louvain recouvrent partiellement les *circles* ;
- la couche métier rend les résultats plus actionnables ;
- la prédiction de liens atteint des performances très élevées.

Limites et perspectives

Limites

- caractéristiques anonymisées ;
- correspondance imparfaite entre Louvain et *circles* ;
- comparaison locale approfondie limitée à deux ego-networks.

Perspectives

- analyser tous les ego-networks ;
- tester d'autres architectures GNN ;
- approfondir l'explicabilité ;
- exploiter davantage les features anonymisées.

Conclusion

Ce projet a permis de :

- construire et analyser un graphe social Facebook ;
- identifier les nœuds les plus centraux ;
- détecter des communautés avec Louvain ;
- comparer les communautés détectées aux *circles* ;
- proposer une lecture métier des résultats ;
- résoudre une tâche de prédiction de liens.

Conclusion générale : l'analyse de graphes constitue une approche pertinente pour comprendre, structurer et prédire des phénomènes relationnels dans un réseau social réel.

Merci

Merci pour votre attention